AI Talent Hub ИТМО

Multimodality in LLM’s

1.1

Мультимодальность

Определение

- Мультимодальные LLM - модели, способные обрабатывать различные типы данных — текст, изображения, аудио, видео — и генерировать ответы, учитывая все эти источники информации.

- **Примеры применения:** визуальный вопрос-ответ (VQA), генерация описаний изображений, мультимодальные диалоги, управление роботами, генерация видео по тексту.

Историческая справка:

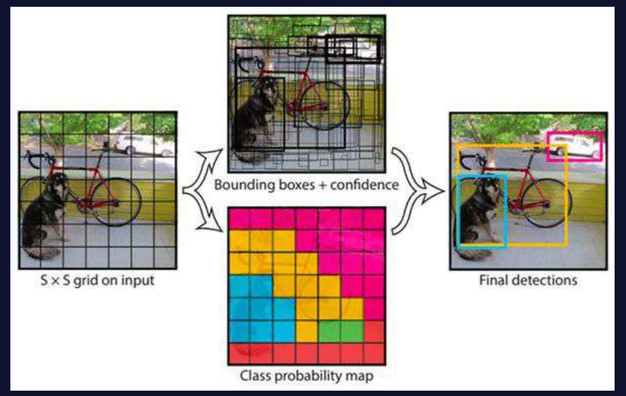

1. Ранние этапы (до 2010 года)

- Изначально ИИ-модели были специализированы на одной модальности: текст (например, статистические модели машинного перевода), изображения (например, AlexNet для классификации изображений) или аудио (например, системы распознавания речи).

2. Появление мультимодальности (2010–2015)

- С развитием нейронных сетей начались попытки объединения различных модальностей.
- Пример: модель VQA (Visual Question Answering), которая сочетала обработку изображений и текста для ответов на вопросы по изображениям.

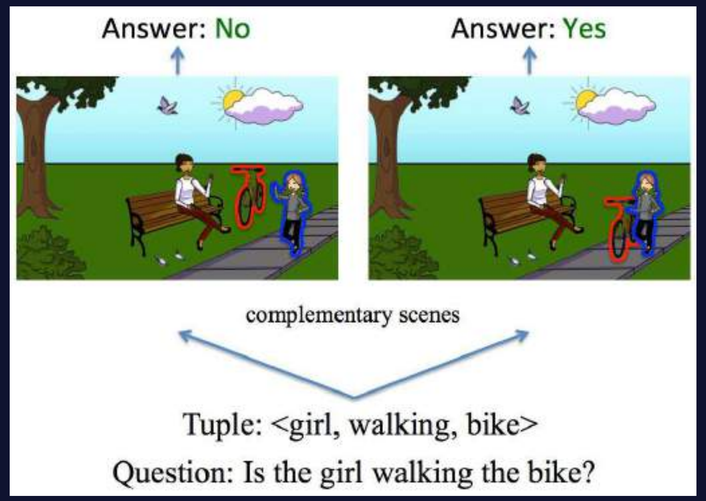

3. Прорыв с использованием трансформеров (2017–2020)

- Введение архитектуры трансформеров (Transformer) в 2017 году стало ключевым моментом.
- Модели, такие как BERT и GPT, продемонстрировали эффективность в обработке текста, а Vision Transformer (ViT) — в обработке изображений.

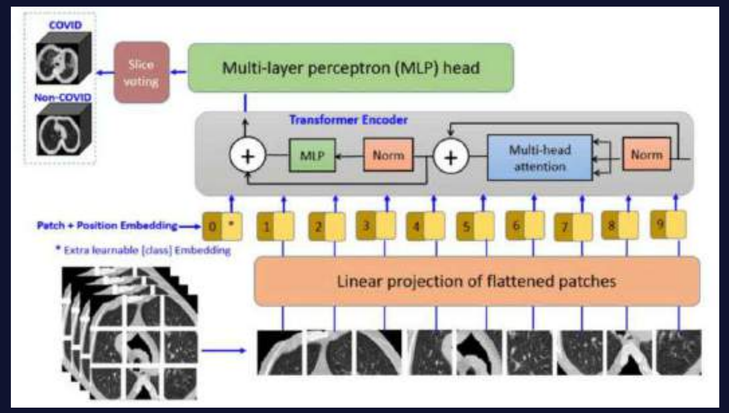

Историческая справка:

4. Появление CLIP и DALL·E (2021)

• OpenAI представила модель CLIP, обученную на 400 миллионах пар изображение-текст, способную сопоставлять визуальные и текстовые данные в общем пространстве эмбеддингов. • DALL·E, также от OpenAI, продемонстрировала возможность генерации изображений по текстовым описаниям.

5. Развитие мультимодальных моделей (2022–2024)

• Появились модели, способные обрабатывать и генерировать данные различных модальностей:

• Flamingo (DeepMind): объединение визуальных и языковых моделей для обучения с малым количеством примеров.

• BLIP-2: использование замороженных визуальных энкодеров и языковых моделей, соединенных через адаптеры. • Gemini (Google): обработка текста, изображений, аудио и видео.

6. Современные тенденции (2025)

• Мультимодальные модели становятся более универсальными, способными обрабатывать разнообразные данные и выполнять сложные задачи, такие как генерация видео по тексту или управление роботами на основе мультимодальных входных данных.

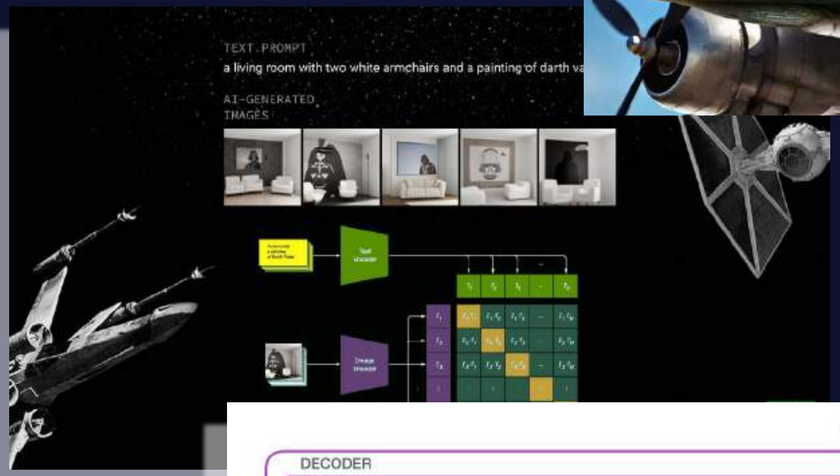

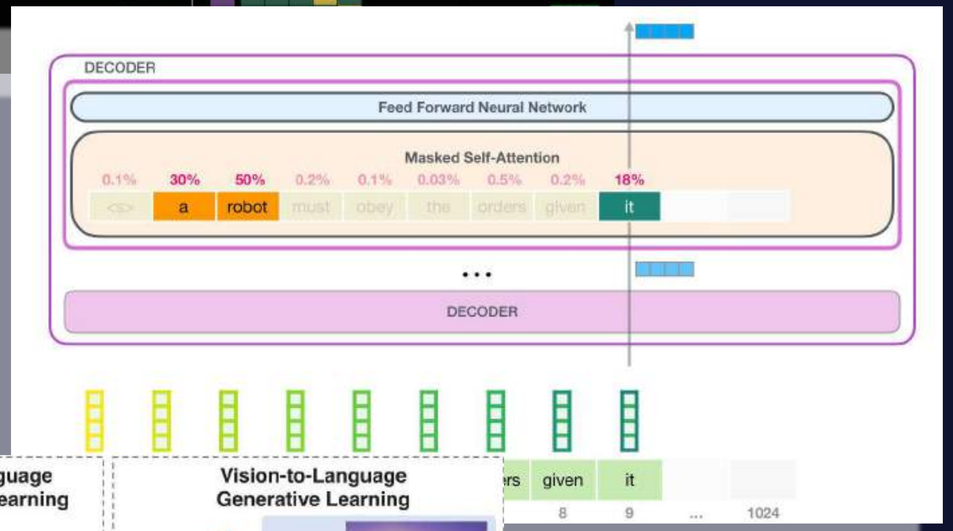

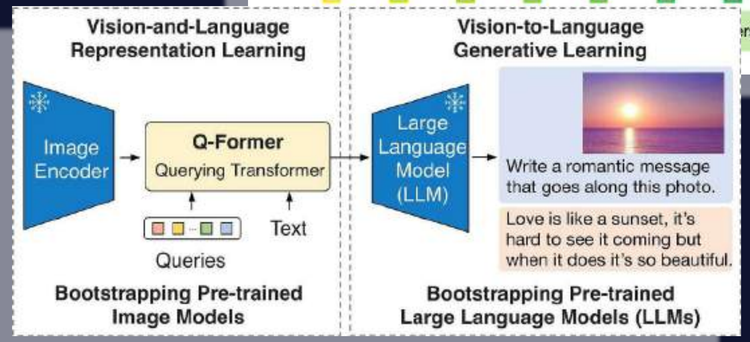

Историческая справка:

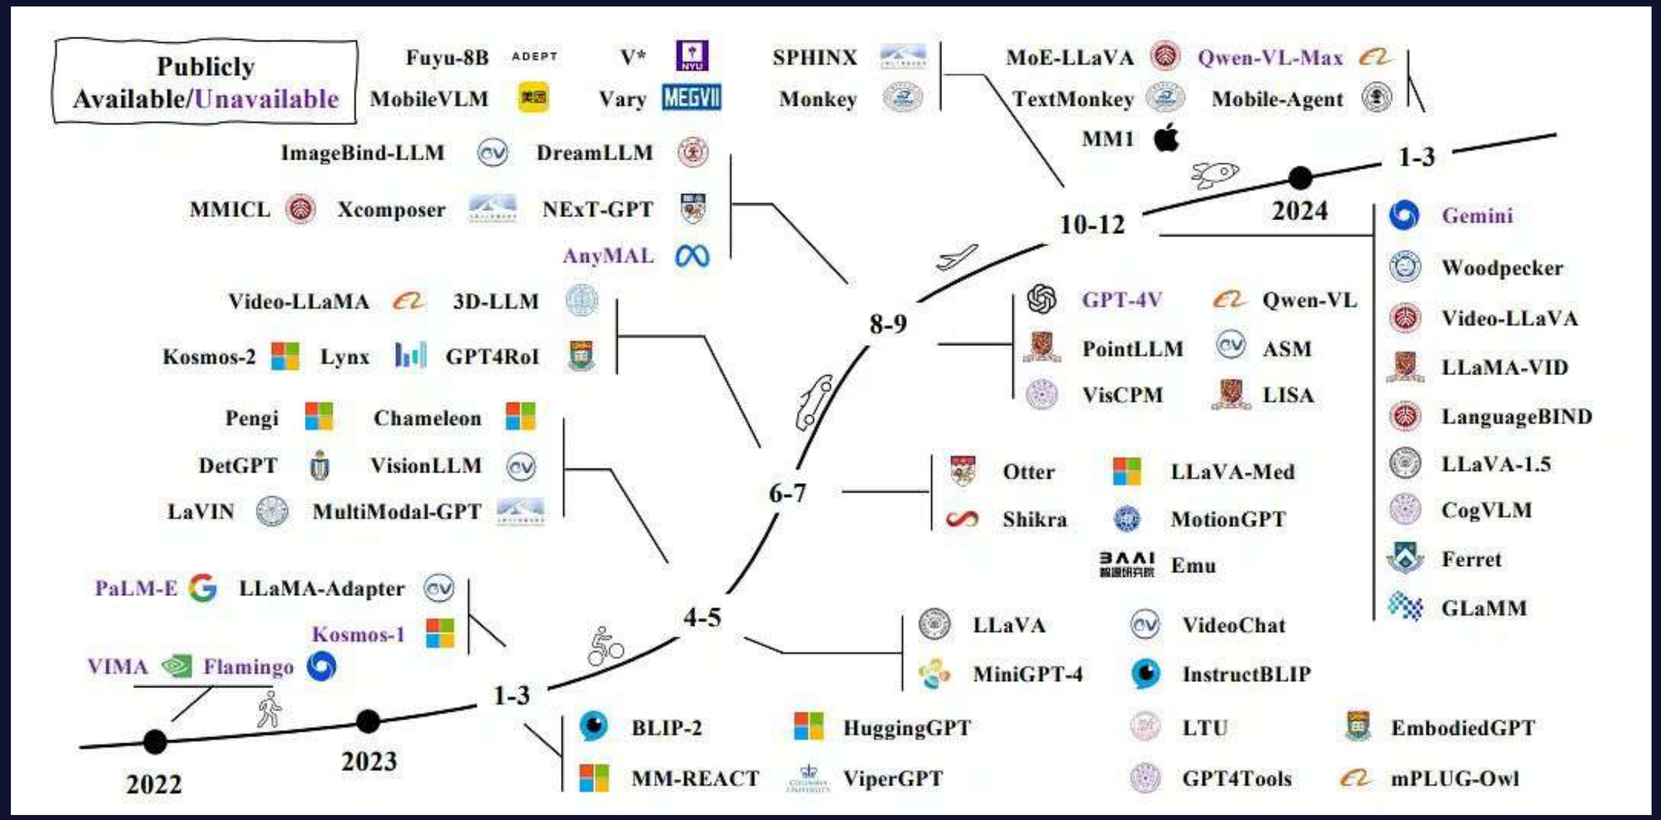

Архитектура CLIP

- Обученный классификатор в рамках "классической" парадигмы *обучения с учителем* способен классифицировать только те объекты, классы которых были в датасете на момент обучения. Сама архитектура нейронной сети устроена так, что выходной слой содержит столько нейронов

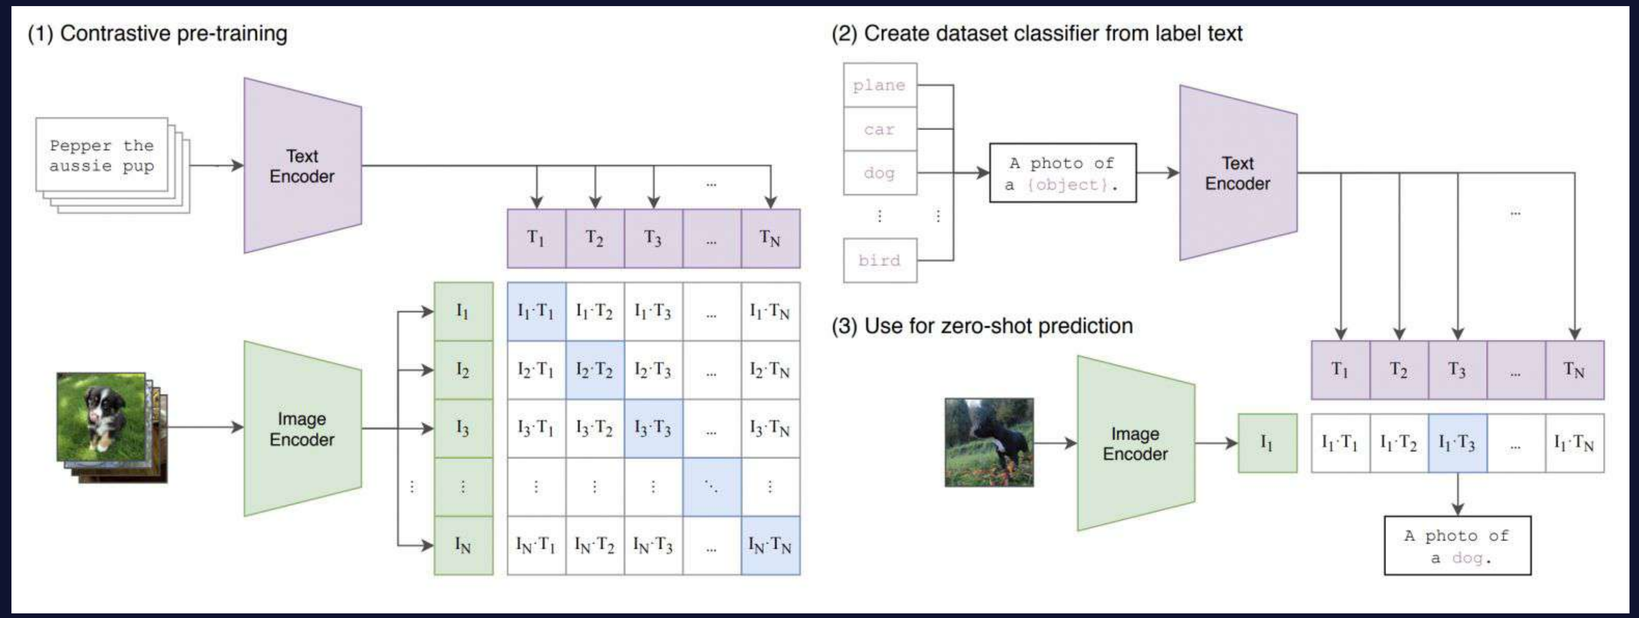

Разбираем CLIP

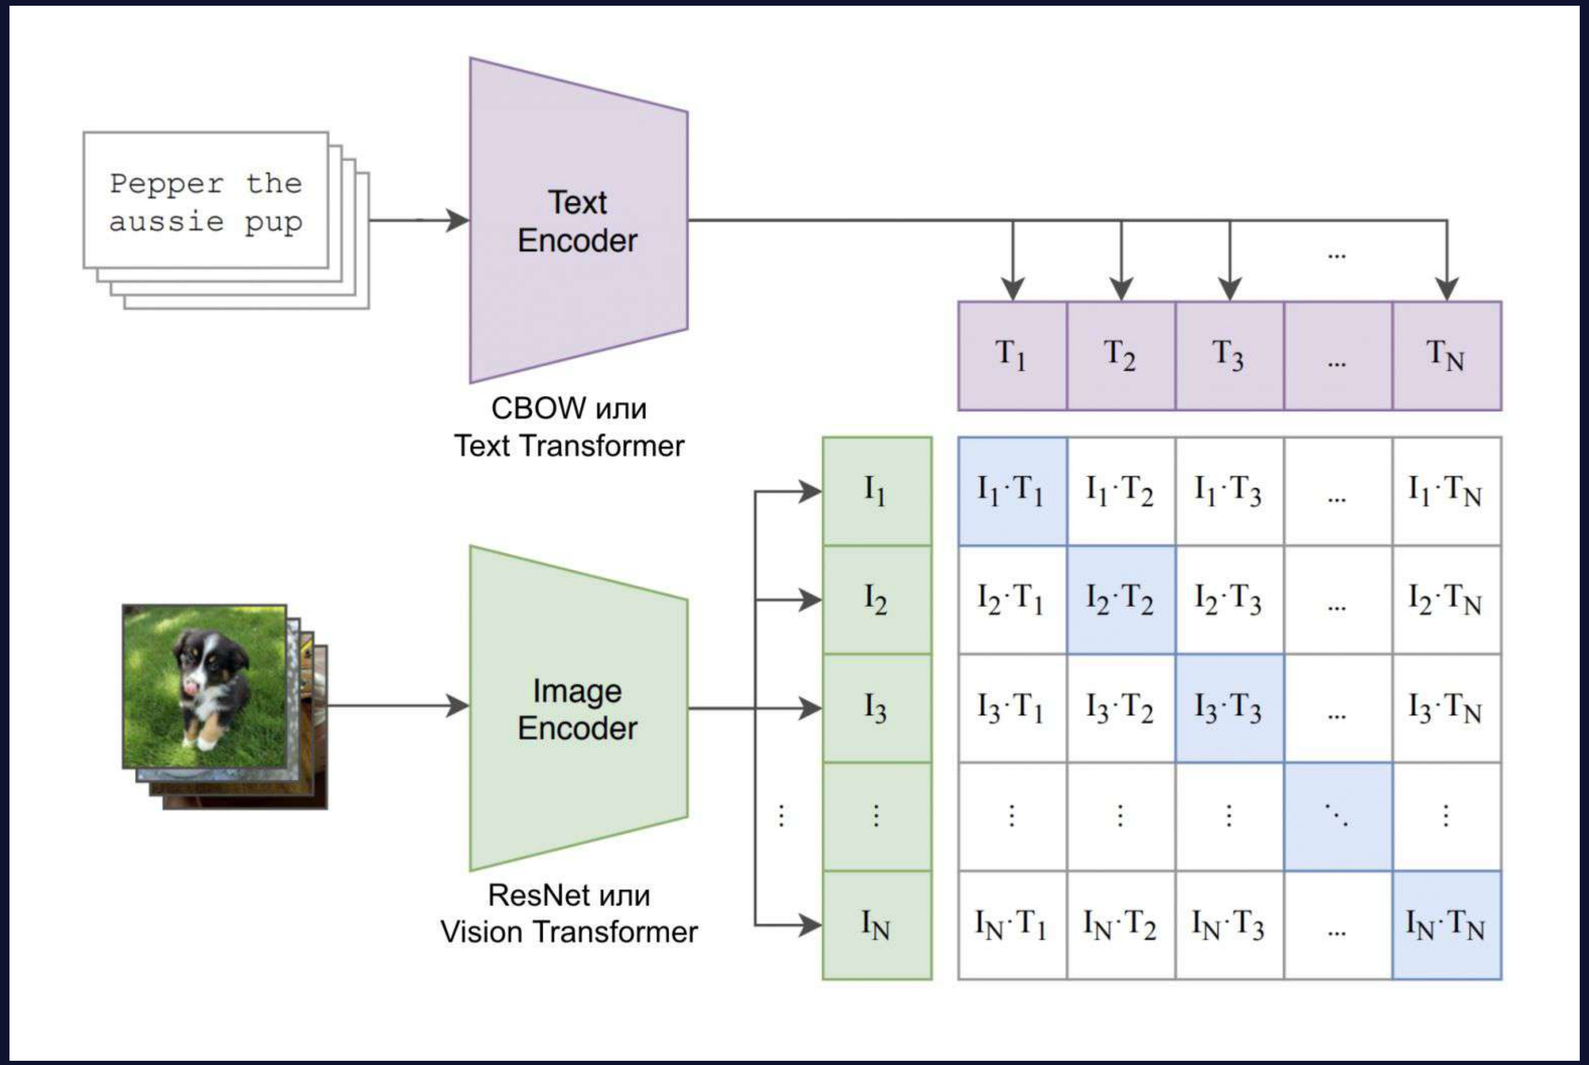

CLIP — есть поэлементное cosine similarity текстовых и визуальных репрезентаций

Разбираем CLIP

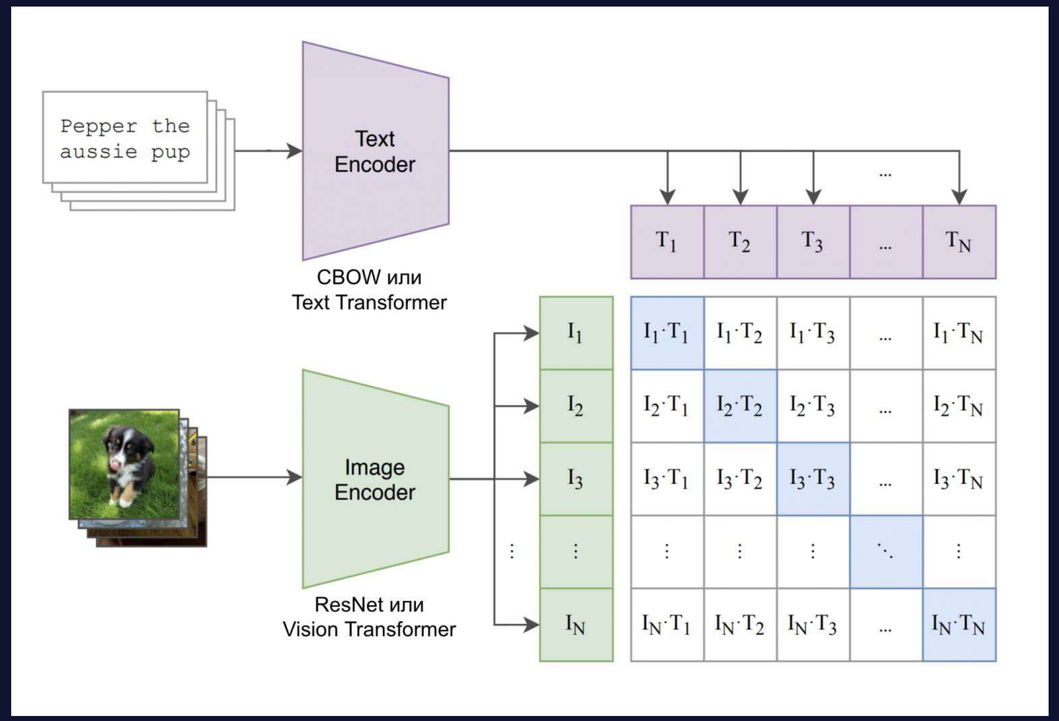

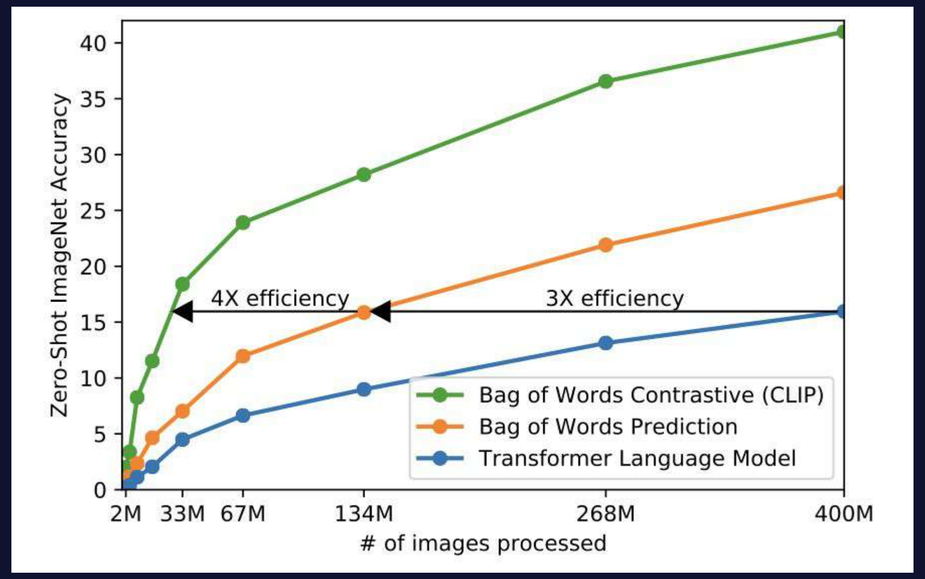

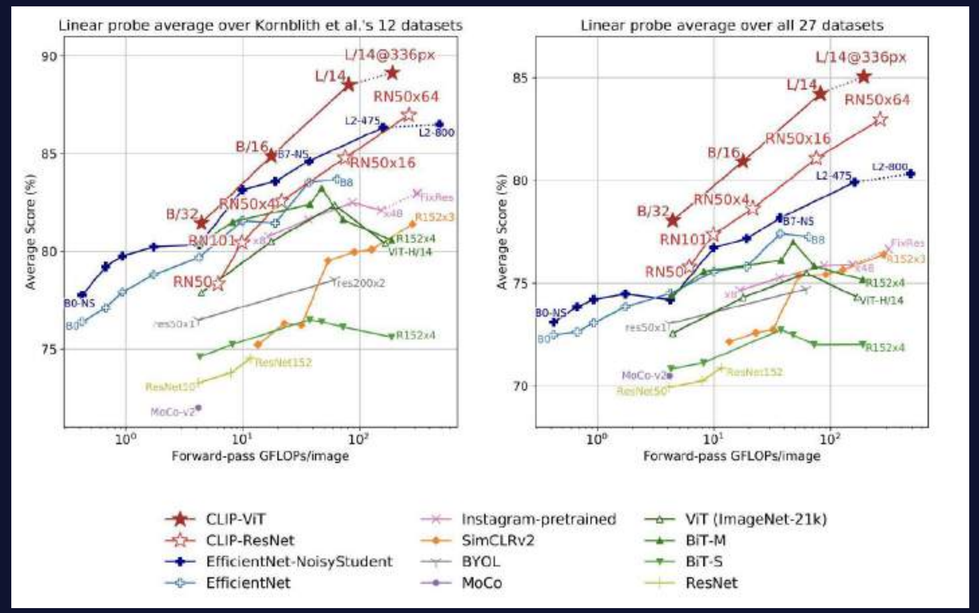

Процесс предобучения

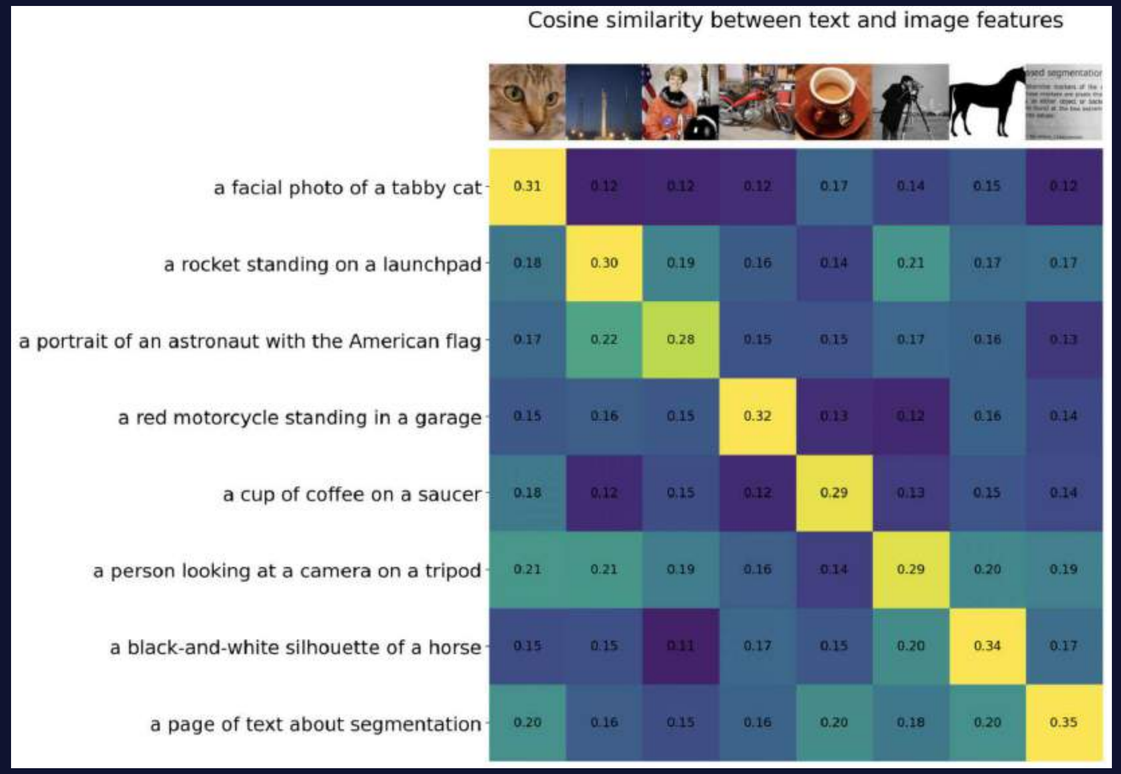

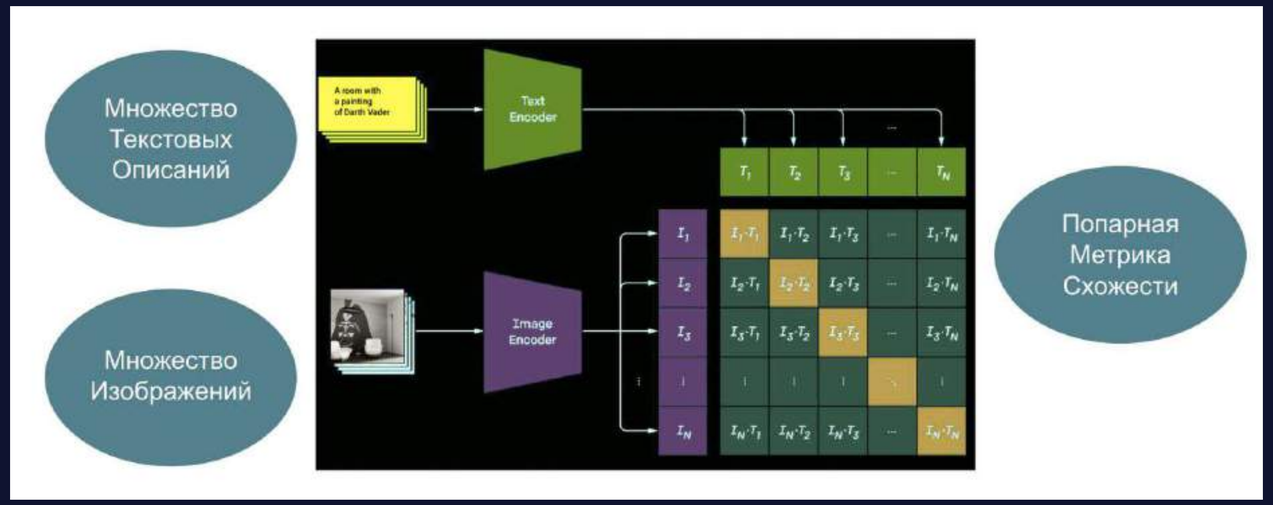

Обучение без обучения

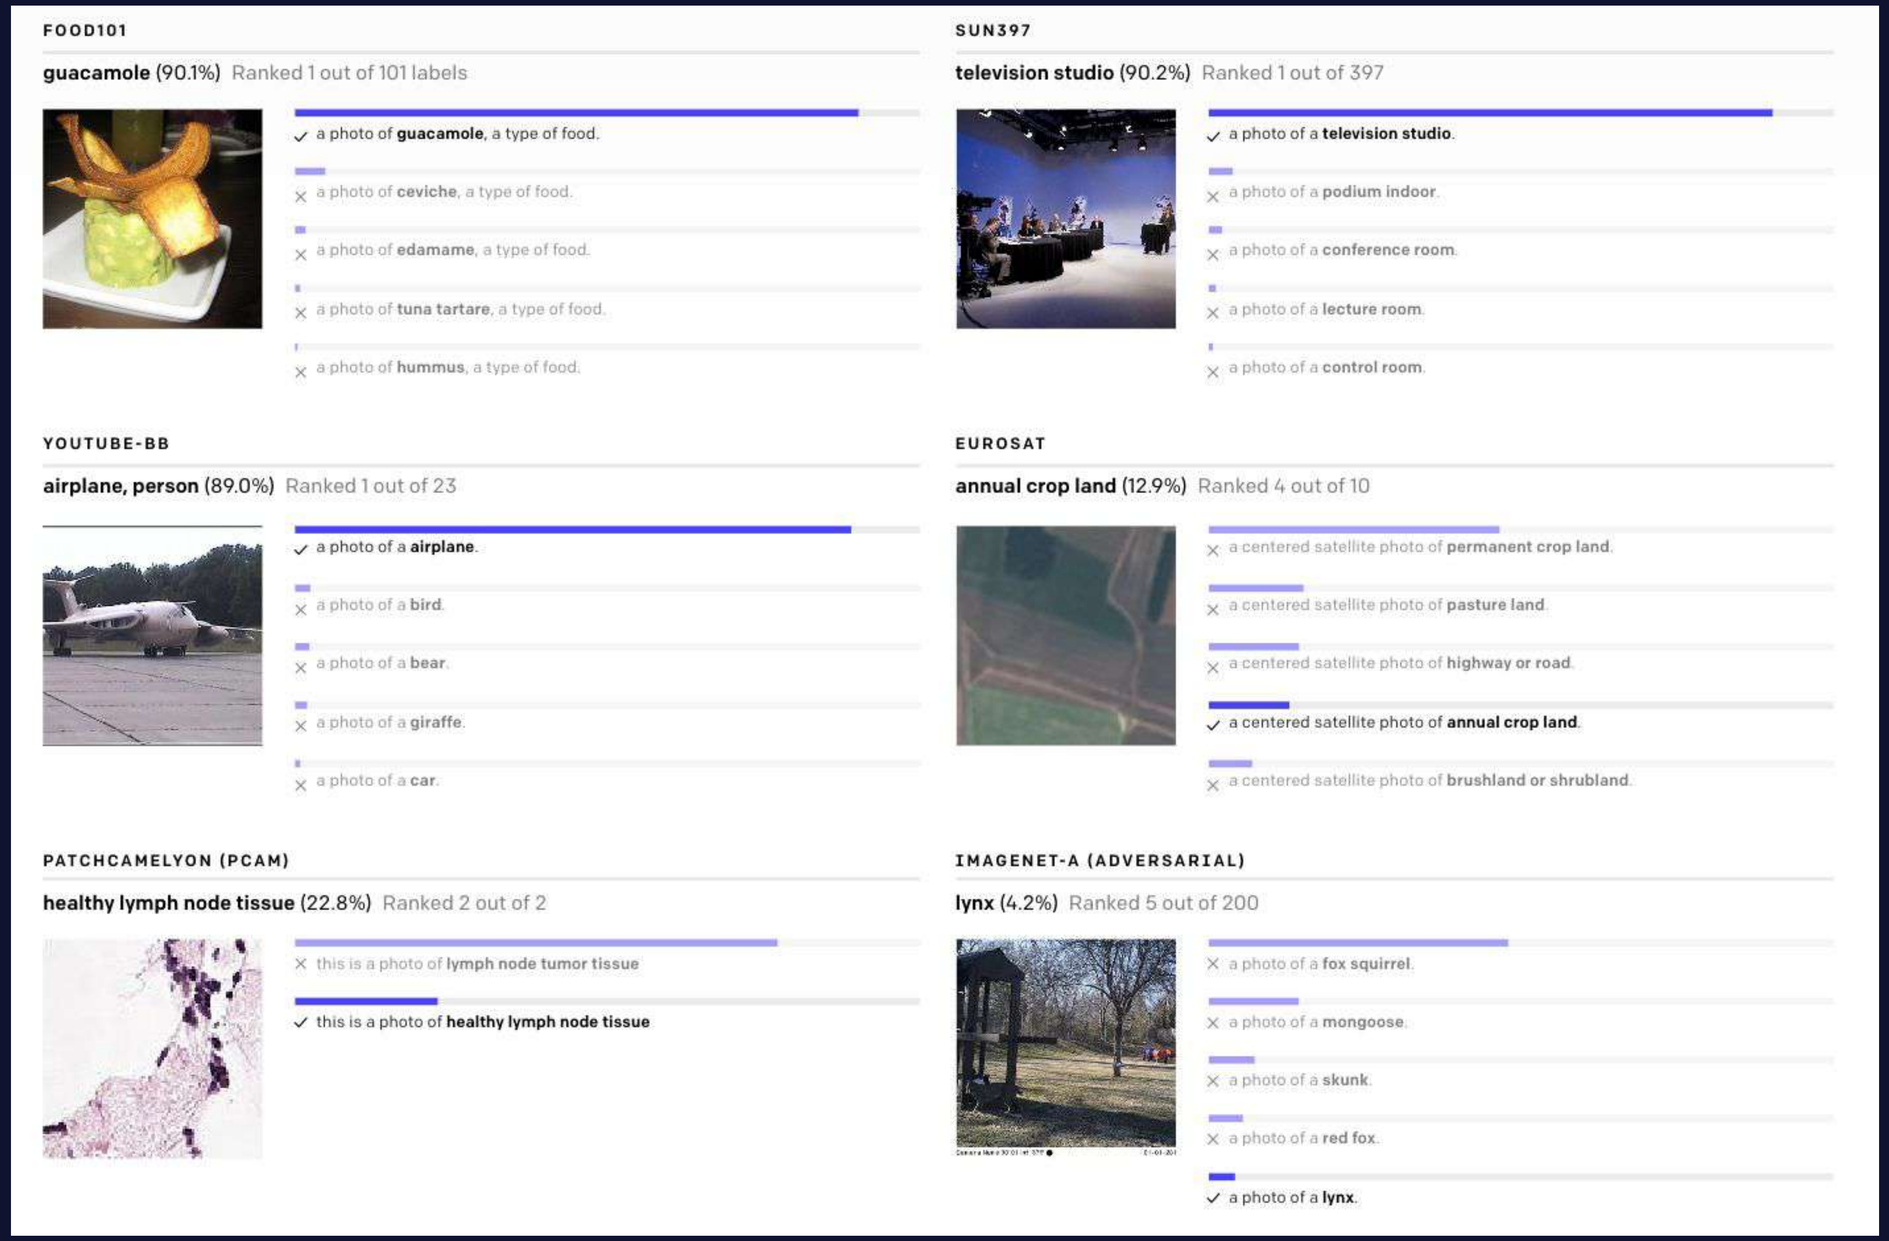

Обучение без обучения

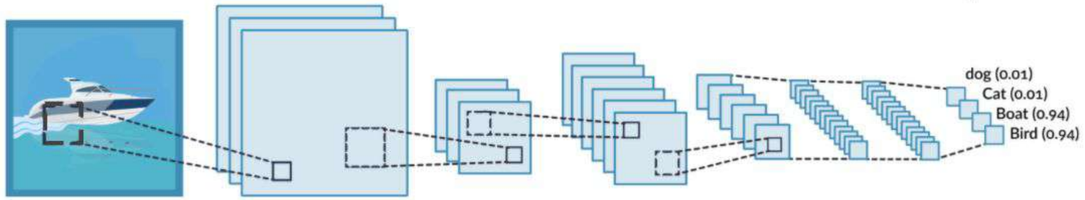

Классификация изображений при помощи сверточной нейросети в рамках “классической” парадигмы

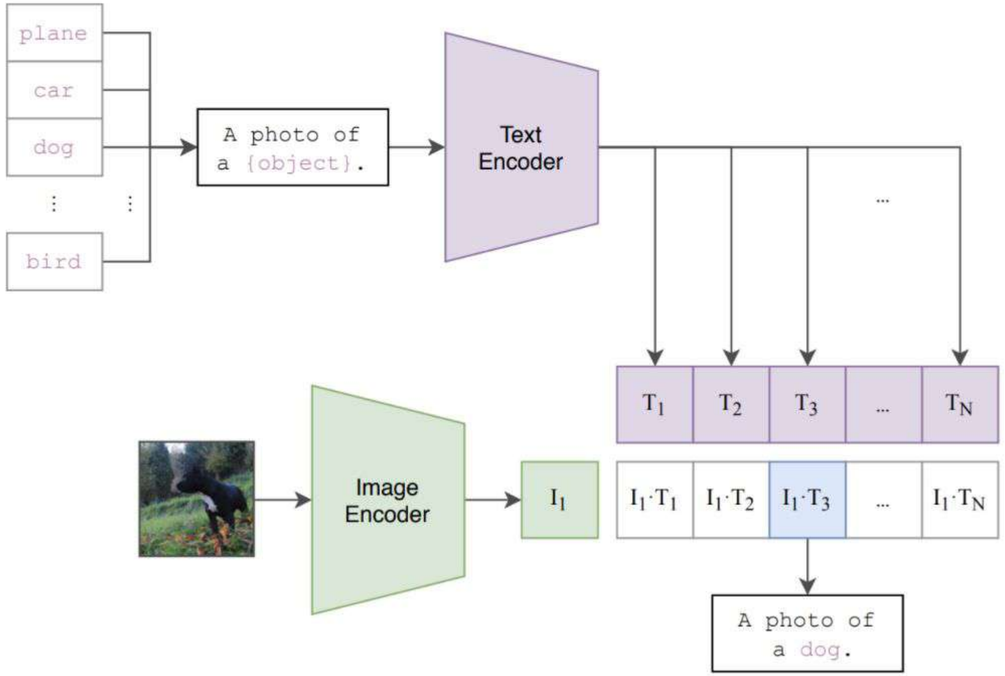

Классификация изображений через схожесть репрезентаций сверточной сети и трансформера в рамках “гибридной” парадигмы

Как приложение к LLM

Visual input example, Constrained JSON Output:

User	Please read the text in this image and return the information in the following JSON format (note xxx is placeholder, if the information is not available in the image, put "N/A" instead). {"class": xxx, "DLN": xxx, "DOB": xxx, "Name": xxx, "Address": xxx, "EXP": xxx, "ISS": xxx, "SEX": xxx, "HGT": xxx, "WGT": xxx, "EYES": xxx, "HAIR": xxx, "DONOR": xxx}
GPT-4V	{"class": "C", "DLN": "1234568", "DOB": "08/31/1977", "Name": "Ima Cardholder", "Address": "2570 24th Street, Anytown, CA 95818", "EXP": "08/31/2014", "ISS": "08/31/2011", "SEX": "F", "HGT": "5-05", "WGT": "125 lbs", "EYES": "BRN", "HAIR": "BRN", "DONOR": "VETERAN"}
LLaVA	{"class": "Driver License", "DLN": "CA123 456 789", "DOB": "01/01/1990", "Name": "Amy", "Address": "Anytown, CA", "EXP": "08/31/2023", "ISS": "Veteran", "SEX": "F", "HGT": "5'5", "WGT": "130", "EYES": "Brown", "HAIR": "Brown", "DONOR": "Unknown"}
LLaVA-1.5	{"class": "C", "DLN": "1132456789", "DOB": "08/23/1971", "Name": "Ima Cardholder", "Address": "Anytown, State, Zip", "EXP": "08/23/2014", "ISS": "California", "SEX": "F", "HGT": "5'5", "WGT": "123", "EYES": "Brown", "HAIR": "Brown", "DONOR": "N/A"}

Как приложение к LLM

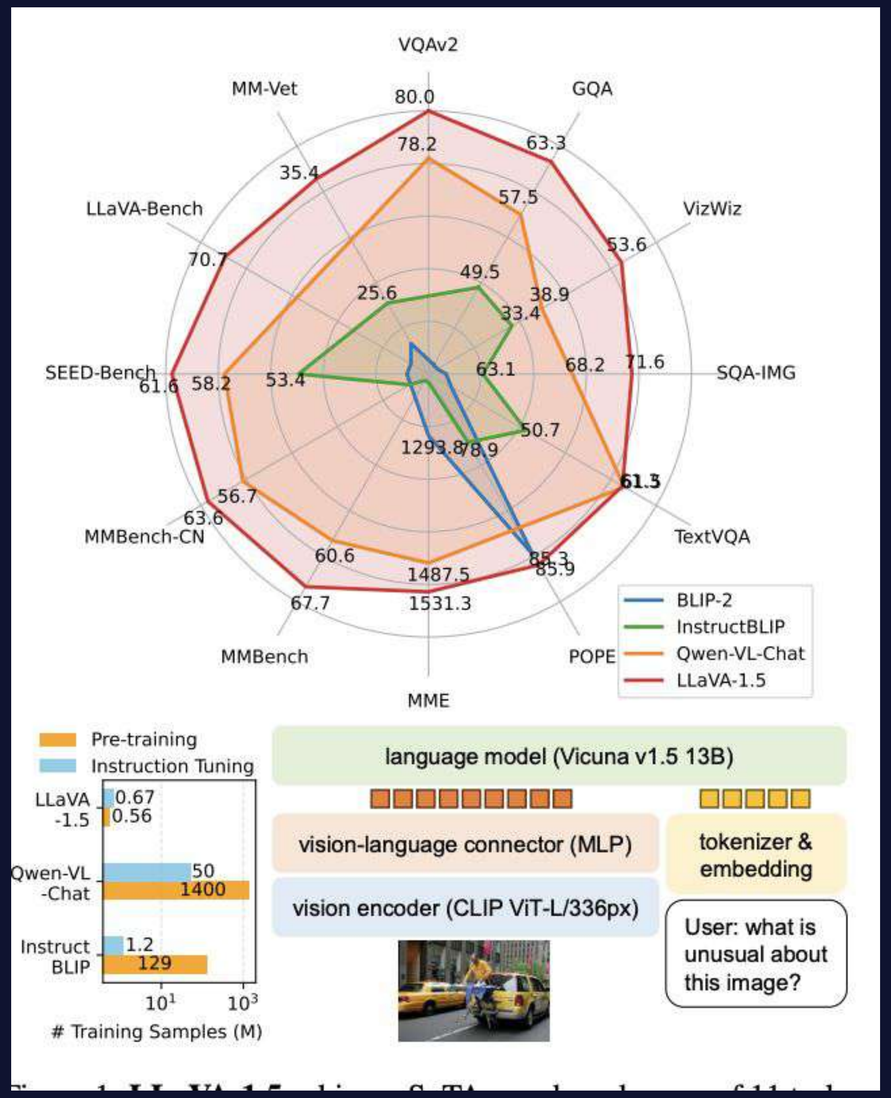

Как приложение к LLM

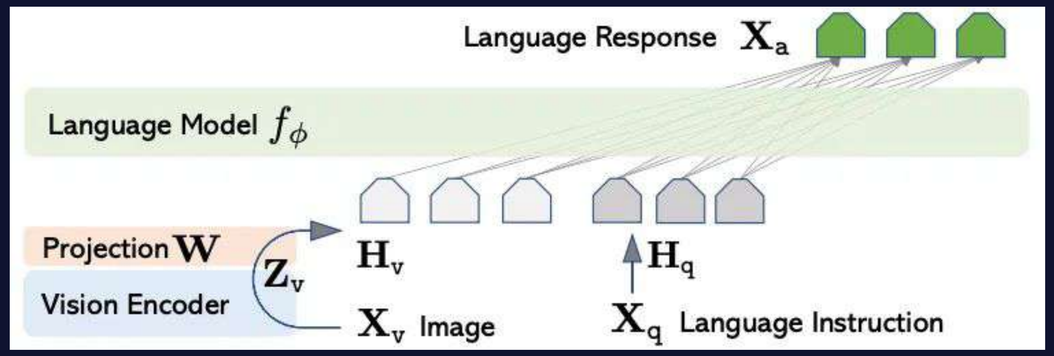

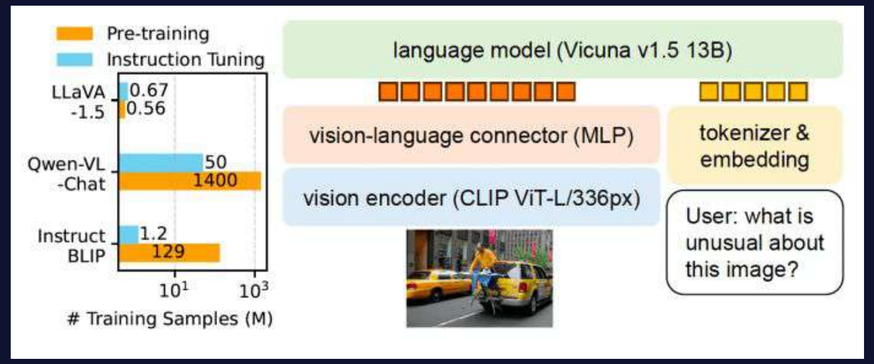

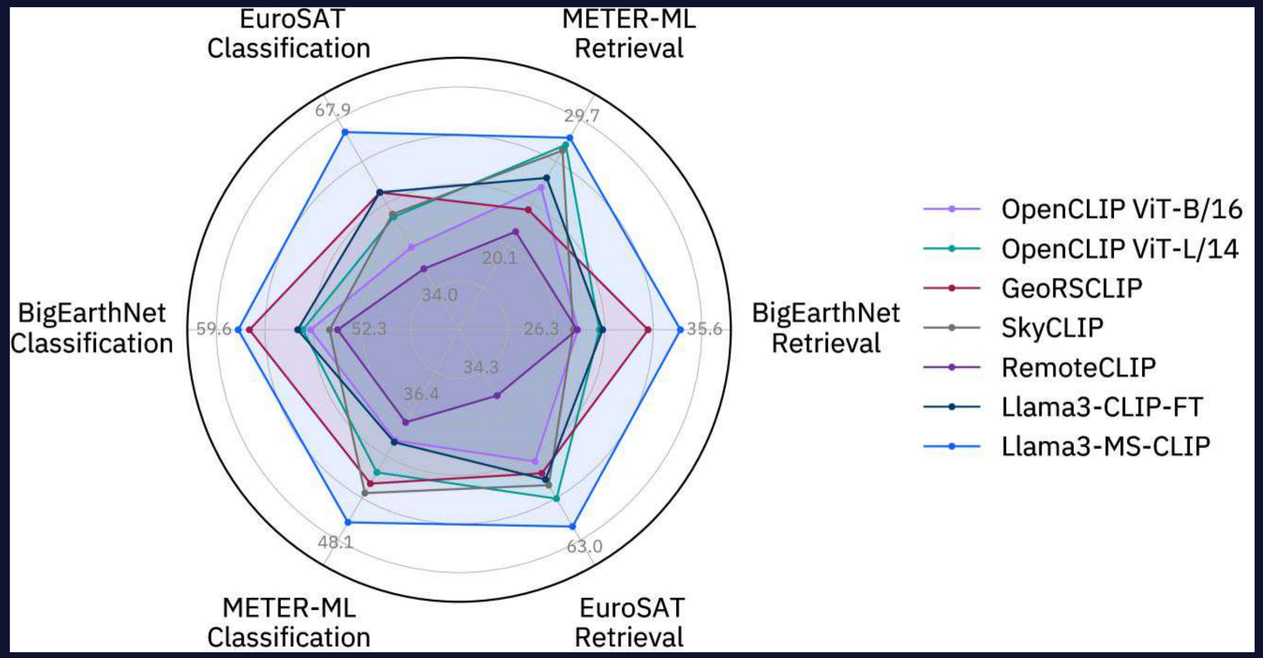

Как приложение к LLM

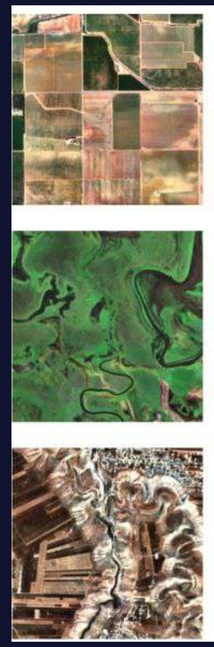

The image is a satellite view of a diverse landscape, featuring agricultural fields, orchards, scrubland, and forested areas. A waterway, possibly a stream or river, is also visible in the image. The land appears to be in a dry condition.

The image is a satellite view of a wetland area, featuring several water bodies such as rivers, lakes, and ponds. The wetland area is green, indicating that it is healthy and thriving.

A satellite image of a landscape featuring a long, winding waterway, scattered residential areas, farmland, and orchards.

The image shows a satellite view of an irregularly shaped landmass with a complex coastline, surrounded by a mix of blue and green ocean waters. The vegetation on the landmass is a mix of green and brown, indicating a combination of healthy and dying plants.

The image shows a brown land surface with distinct patterns and textures, including rocky areas and patches of dirt. There are objects and structures visible on the land surface, including a building and a road.

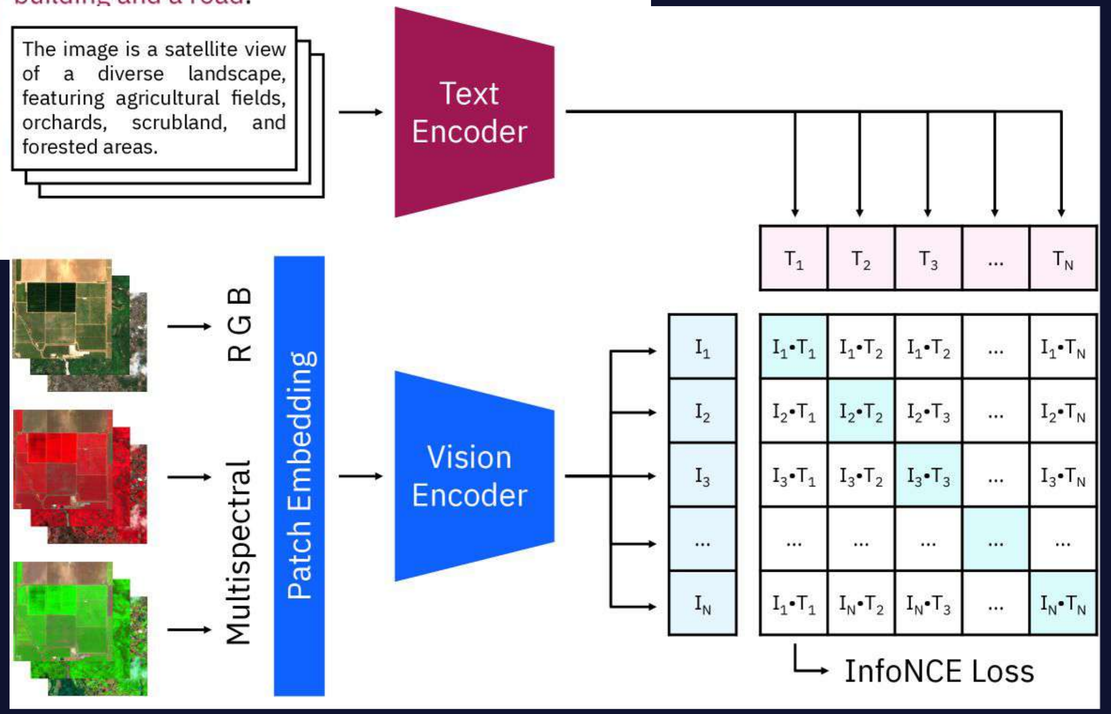

Примеры

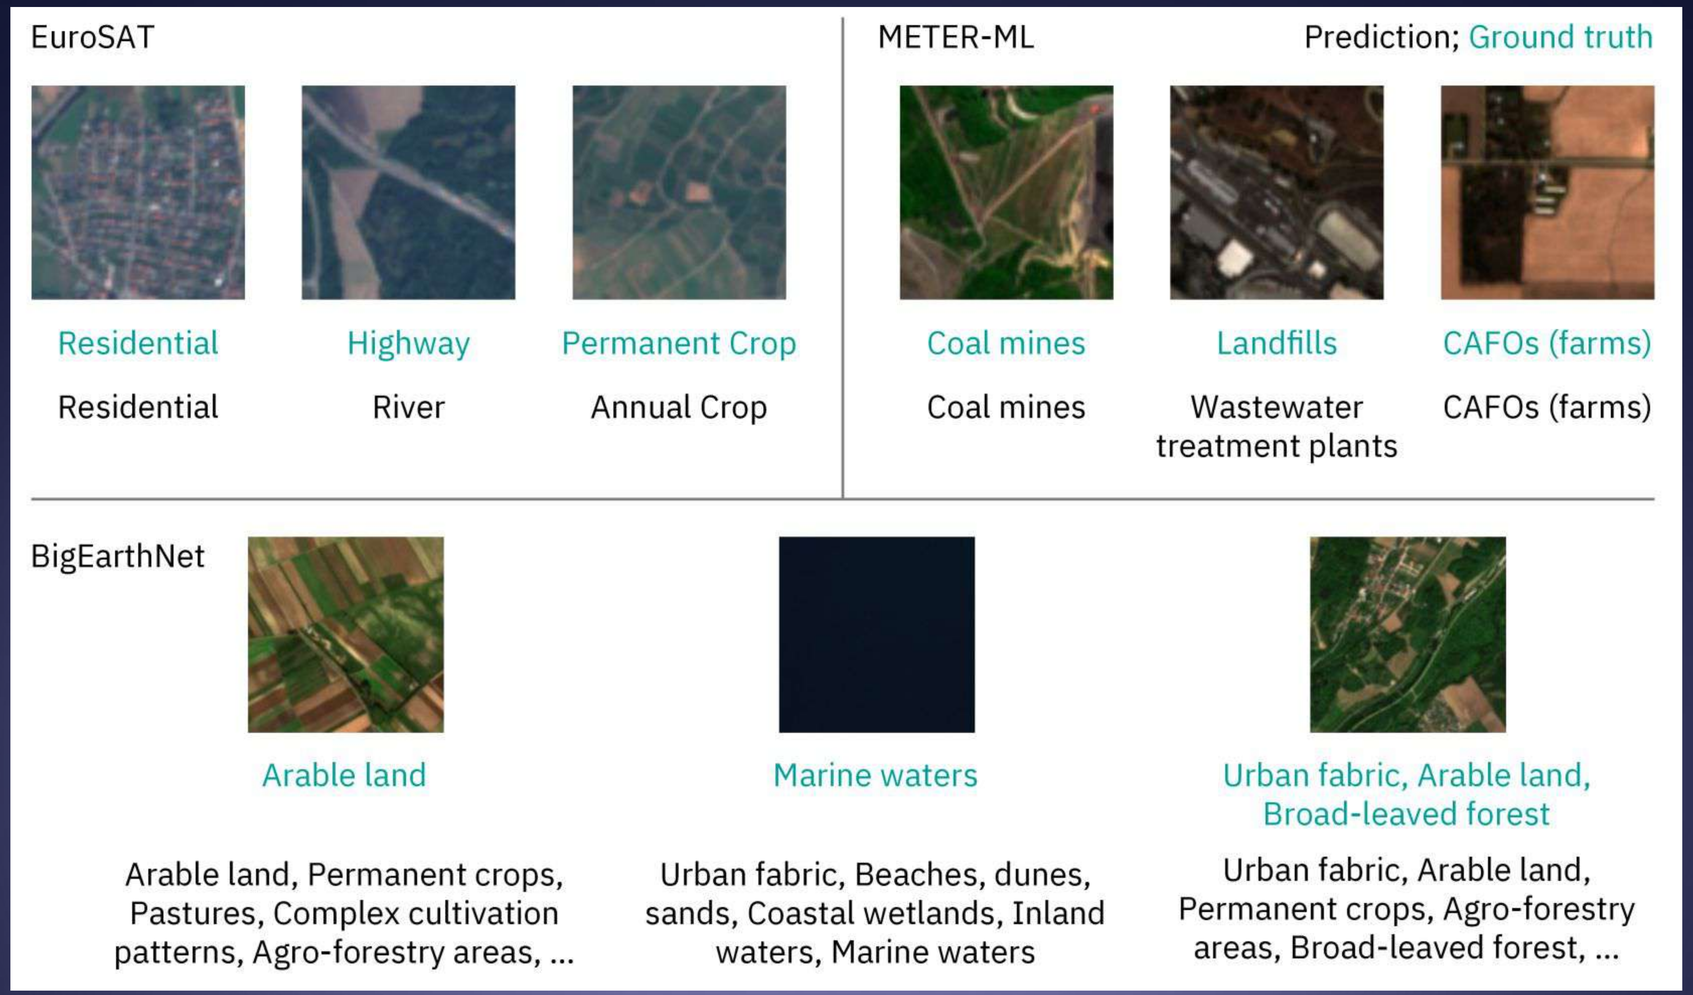
EuroSAT
METER-ML
Prediction; Ground truth
Residential
Highway
Permanent Crop
Coal mines
Landfills
CAFOs (farms)
Residential
River
Annual Crop
Coal mines
Wastewater treatment plants
CAFOs (farms)
BigEarthNet
Arable land
Marine waters
Urban fabric, Arable land, Broad-leaved forest
Arable land, Permanent crops, Pastures, Complex cultivation patterns, Agro-forestry areas, ...
Urban fabric, Beaches, dunes, sands, Coastal wetlands, Inland waters, Marine waters
Urban fabric, Arable land, Permanent crops, Agro-forestry areas, Broad-leaved forest, ...

Технология: архитектура

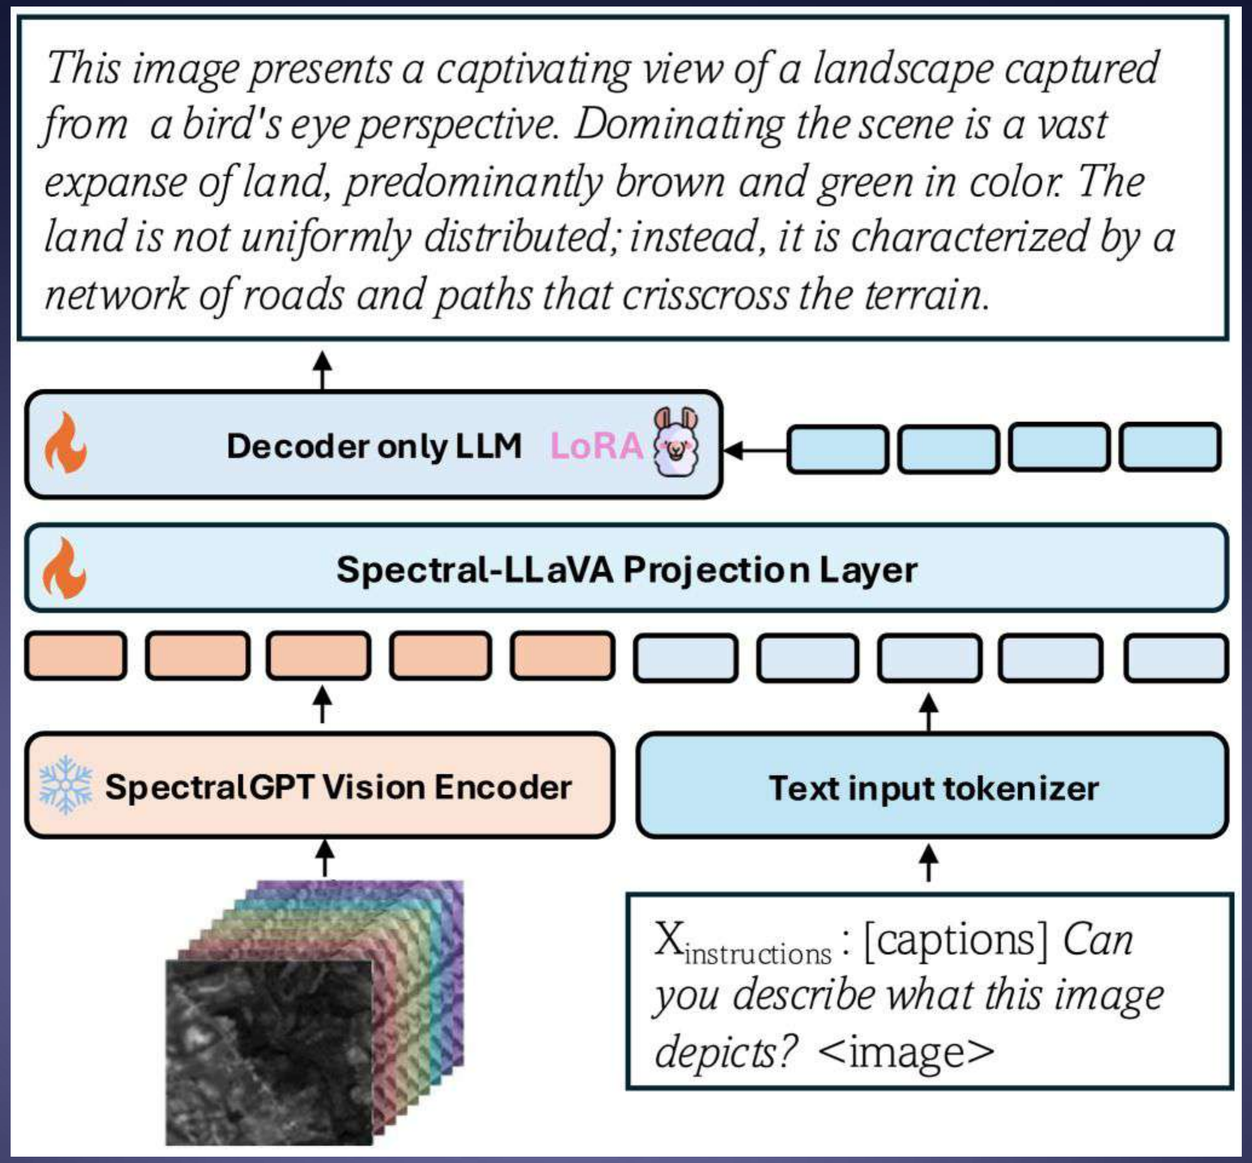

Технология: простанство признаков

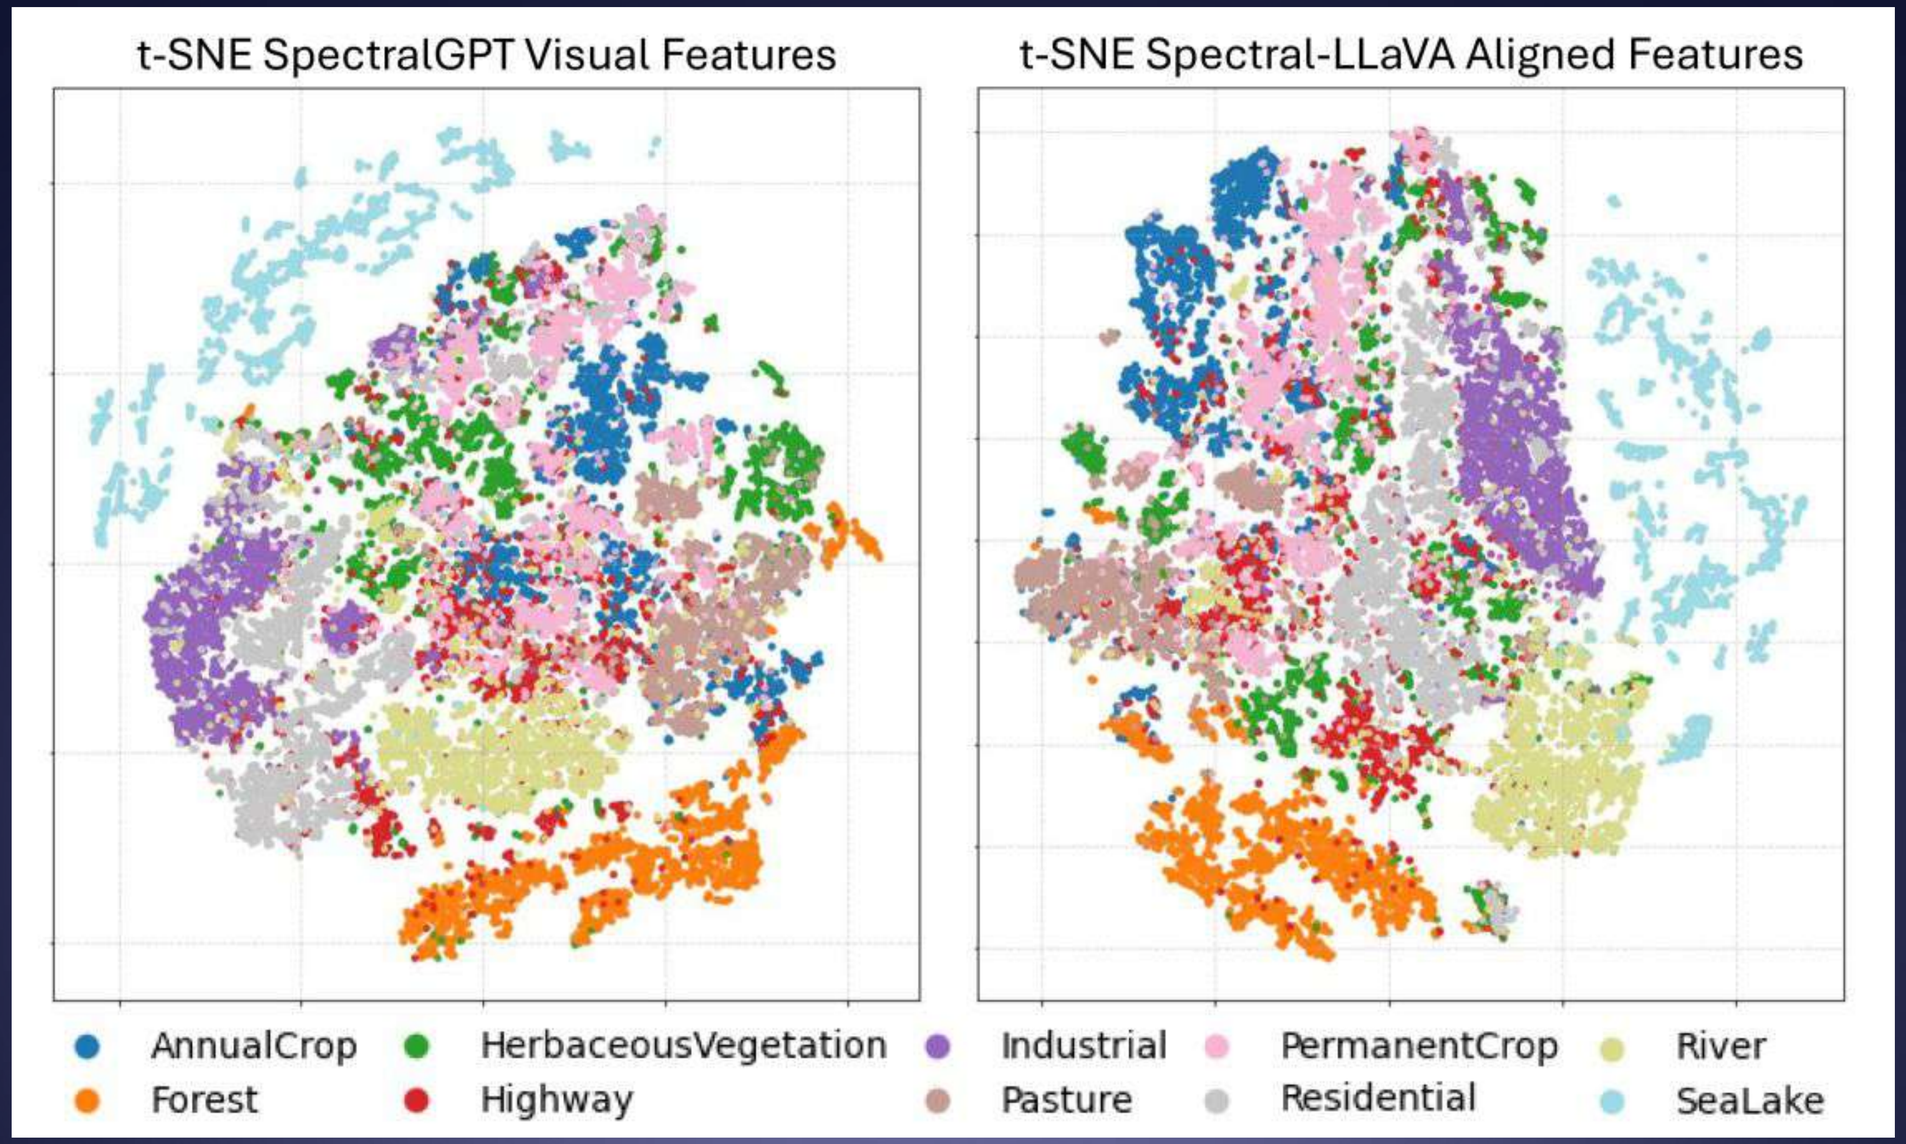

Технология (нашей модели)

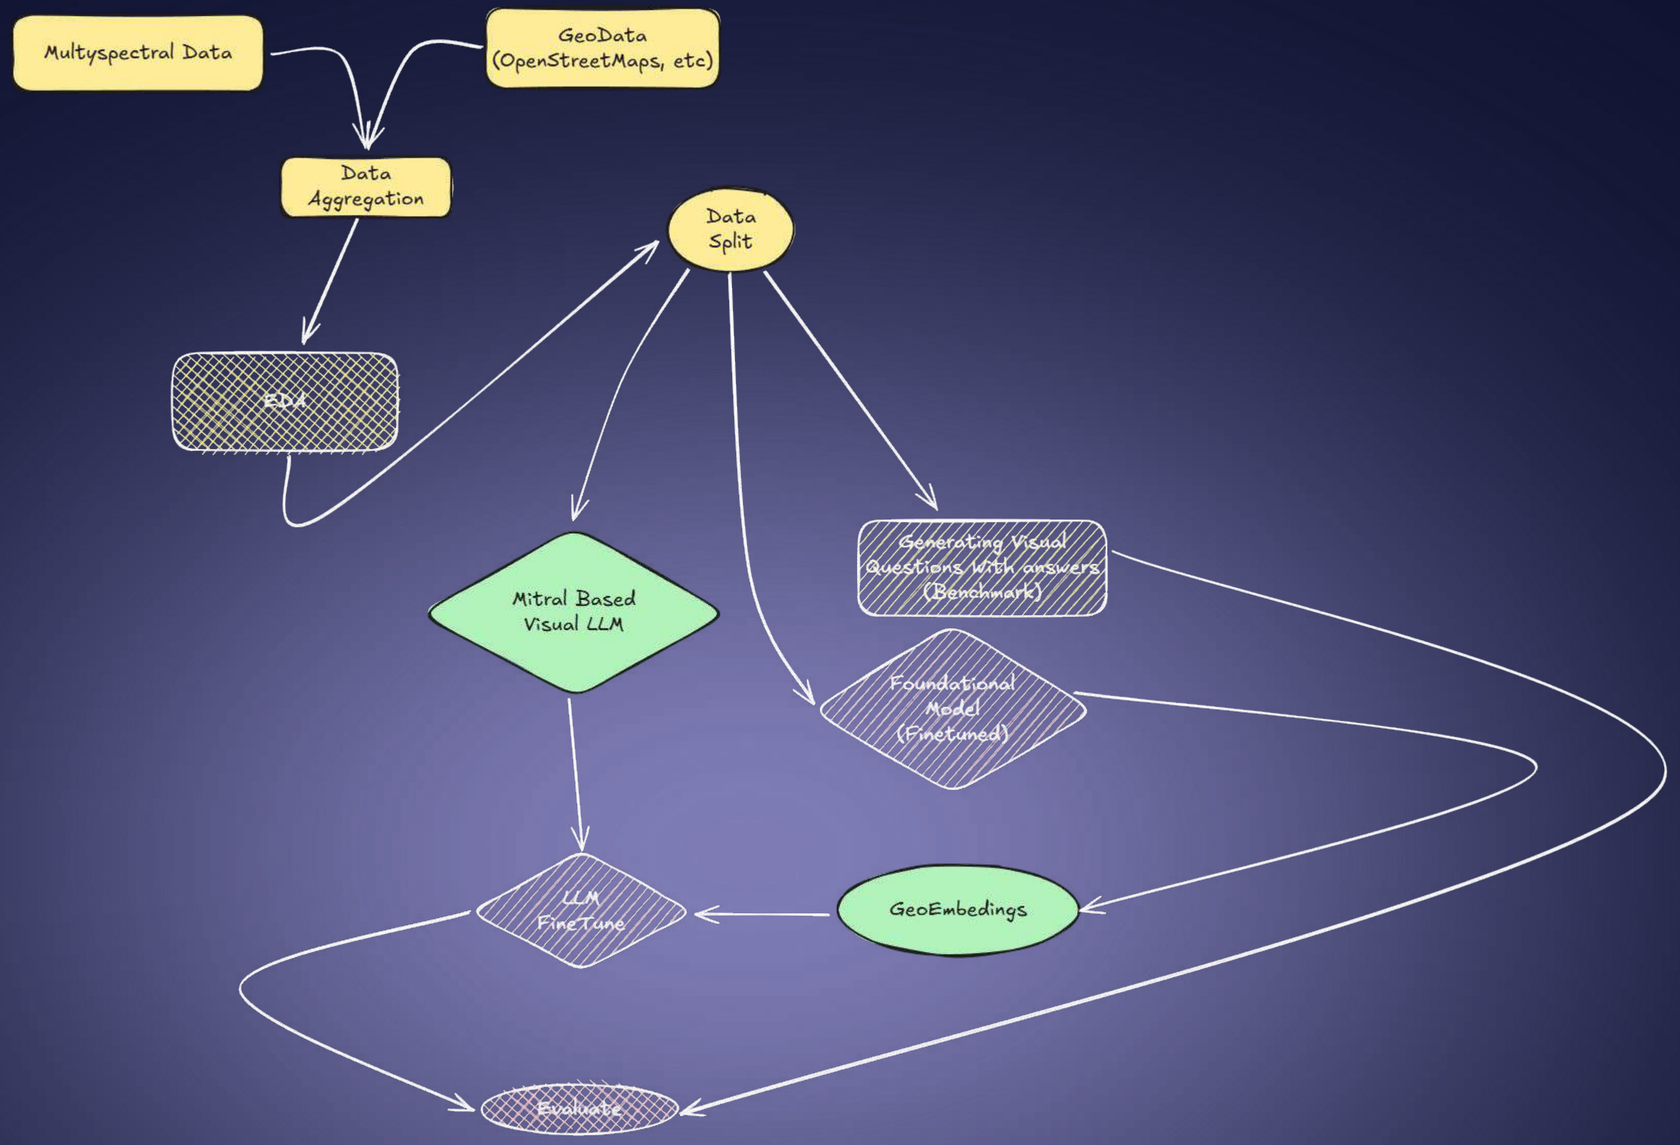

Пример модели:

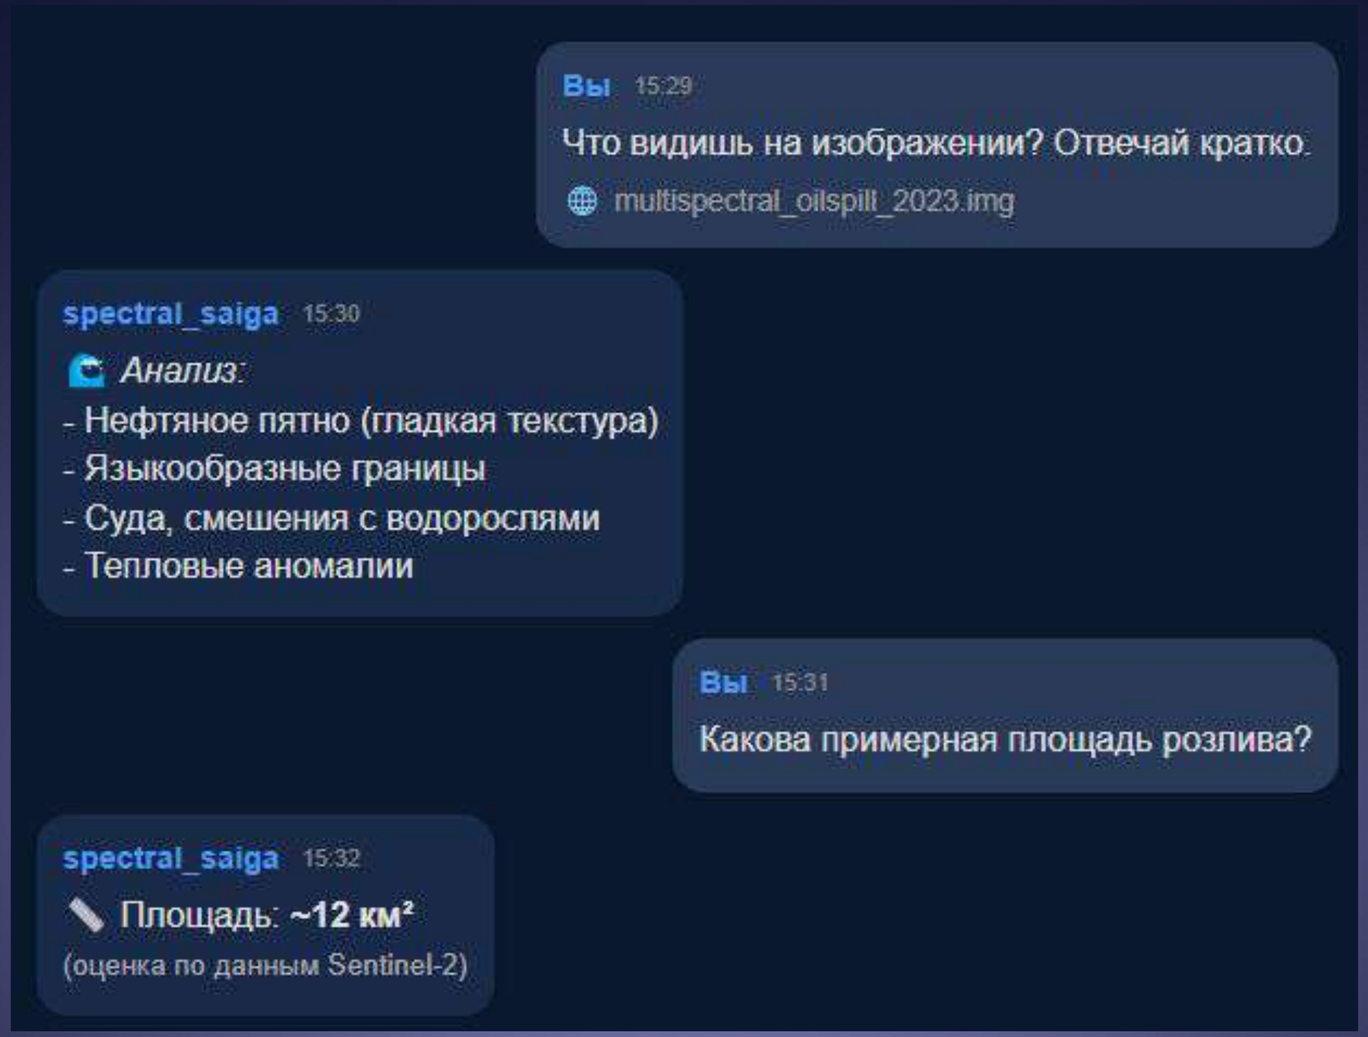
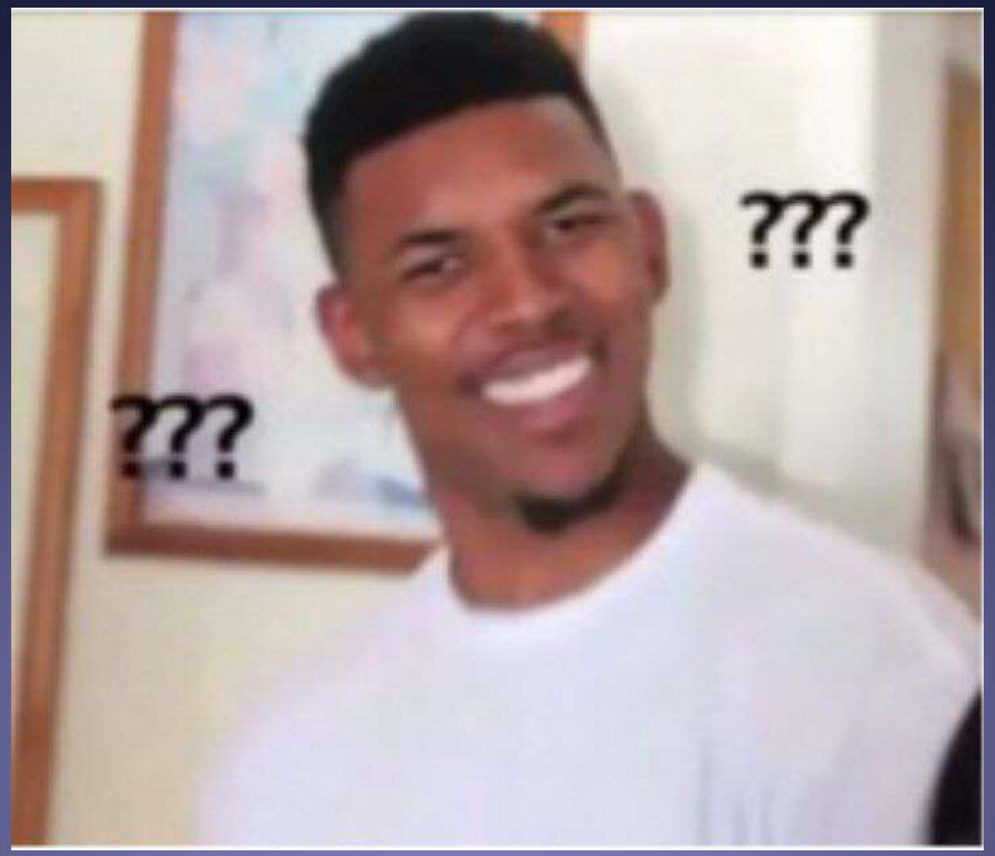
Вопросы: