Stable Diffusion finetune

Links

https://dreambooth.github.io/

https://huggingface.co/blog/dreambooth

https://github.com/huggingface/diffusers/tree/main/examples/dreambooth

https://arxiv.org/pdf/2208.01618.pdf

https://arxiv.org/abs/2106.09685

https://stable-diffusion-art.com/lora/

PEFT подходы

- Textual Inversion
- Dreambooth
- LoRA
- Hypernetworks

Textual inversion

Input samples $\xrightarrow{invert}$ "S_*"

→

"Painting of two S_* fishing on a boat"

"A S_* backpack"

"Banksy art of S_*"

"A S_* themed lunchbox"

→

Textual inversion

вместо целой модели “обучаем” наш текстовый embedding

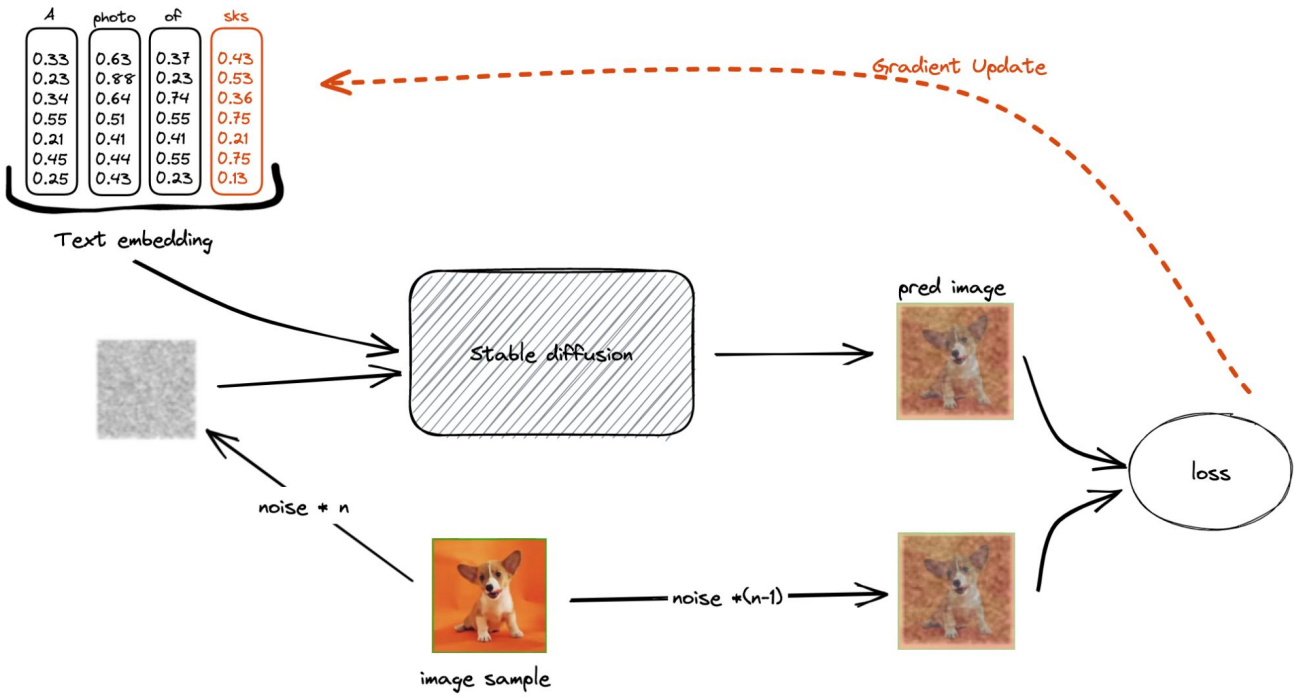

Шаблоны

- “a photo of a S_*.”,
- “a rendering of a S_*.”,
- “a cropped photo of the S_*.”,
- “the photo of a S_*.”,
- “a photo of a clean S_*.”,
- “a photo of a dirty S_*.”,
- “a dark photo of the S_*.”,
- “a photo of my S_*.”,

Full finetune

Full finetune

Связываем наш объект с конкретным токеном

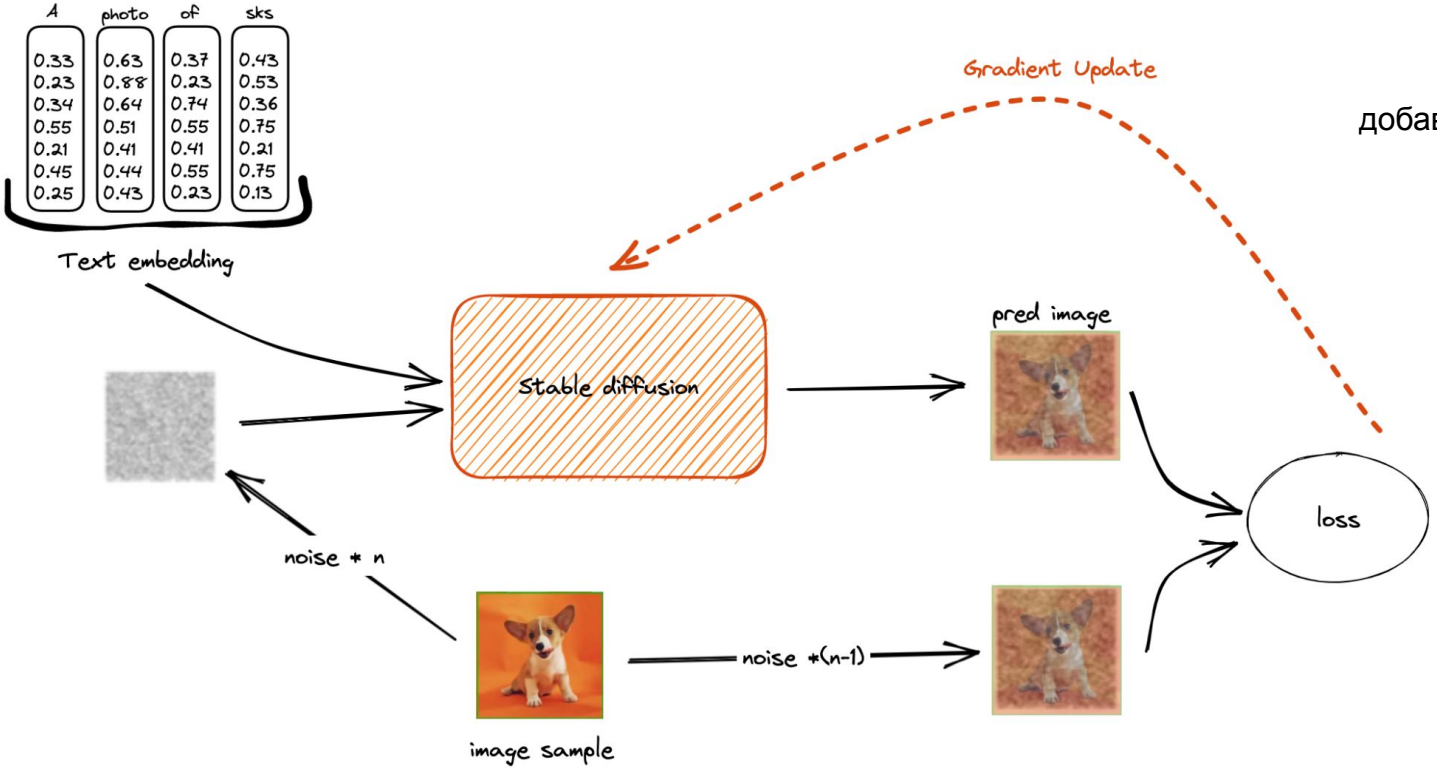

добавляем шум

считаем лосс

обновляем веса

DreamBooth

$$\mathbf{x}_{\text{gen}} = \hat{\mathbf{x}}_\theta(\boldsymbol{\epsilon}, \mathbf{c})$$

ε - шум; c - conditional вектор; x_θ - модель

Считаем MSE loss для шума из разницы изображений

функция потерь

$$\mathbb{E}_{\mathbf{x},\mathbf{c},\boldsymbol{\epsilon},t}\left[w_t \|\hat{\mathbf{x}}_\theta(\alpha_t \mathbf{x} + \sigma_t \boldsymbol{\epsilon}, \mathbf{c}) - \mathbf{x}\|_2^2\right]$$

функция потерь с регуляризацией

$$\mathbb{E}_{\mathbf{x},\mathbf{c},\boldsymbol{\epsilon},\boldsymbol{\epsilon}',t}[w_t \|\hat{\mathbf{x}}_\theta(\alpha_t \mathbf{x} + \sigma_t \boldsymbol{\epsilon}, \mathbf{c}) - \mathbf{x}\|_2^2 + \lambda w_{t'} \|\hat{\mathbf{x}}_\theta(\alpha_{t'} \mathbf{x}_{\text{pr}} + \sigma_{t'} \boldsymbol{\epsilon}', \mathbf{c}_{\text{pr}}) - \mathbf{x}_{\text{pr}}\|_2^2],$$

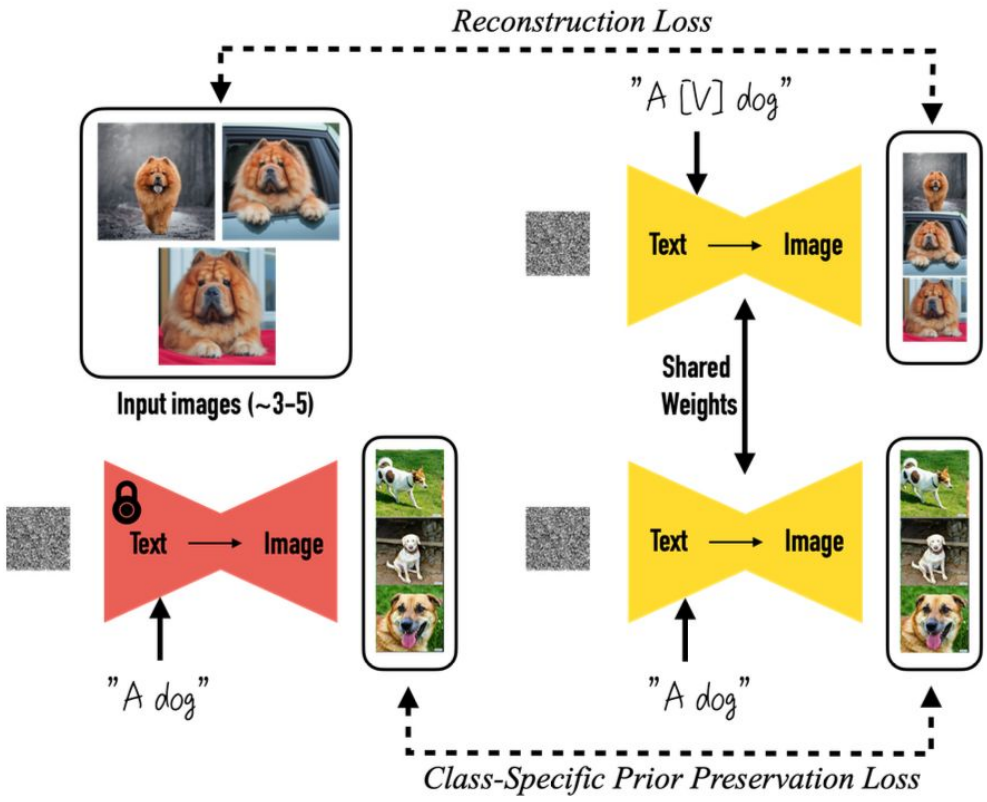

DreamBooth

Цель: добавить в модель конкретный объект при этом не потерять накопленные знания

1. расширяем словарь и соотносим объект с непопулярным токеном[sks] чтобы не было *language drift*
2. Плохая идея выбрать рандомный набор символов “xxy5syt00” токенайзер может их разбить на разные токены
3. внедряем пару “a [identifier] [class noun]” (e.g. cat, dog, watch, etc.)
4. На вход достаточно 5 картинок на разном фоне и с разных ракурсов (максимально разнообразные)
5. тренируем модель целиком, приходится сохранять веса целиком

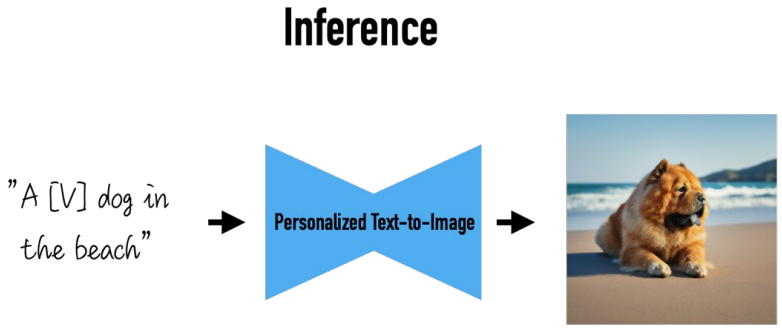

Lora Low-Rank Adaptation

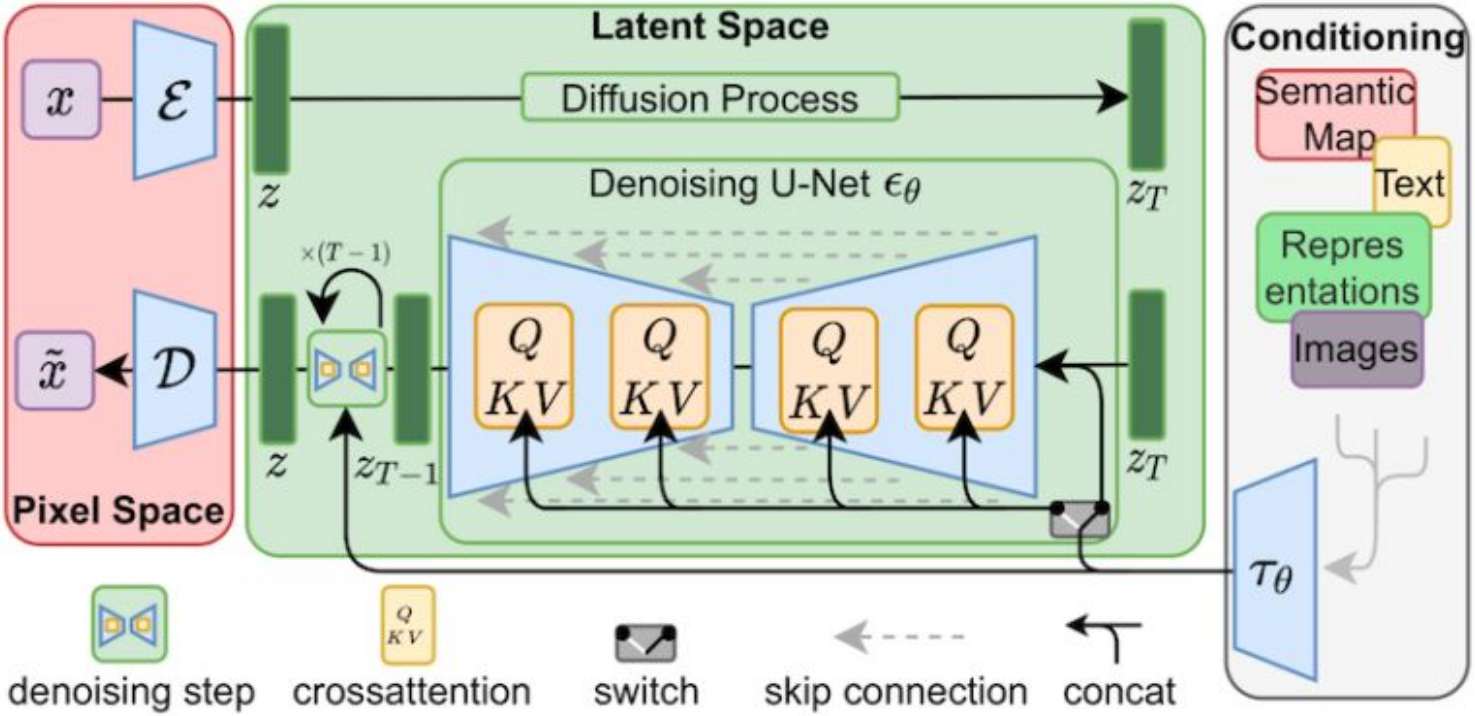

Lora Low-Rank Adaptation

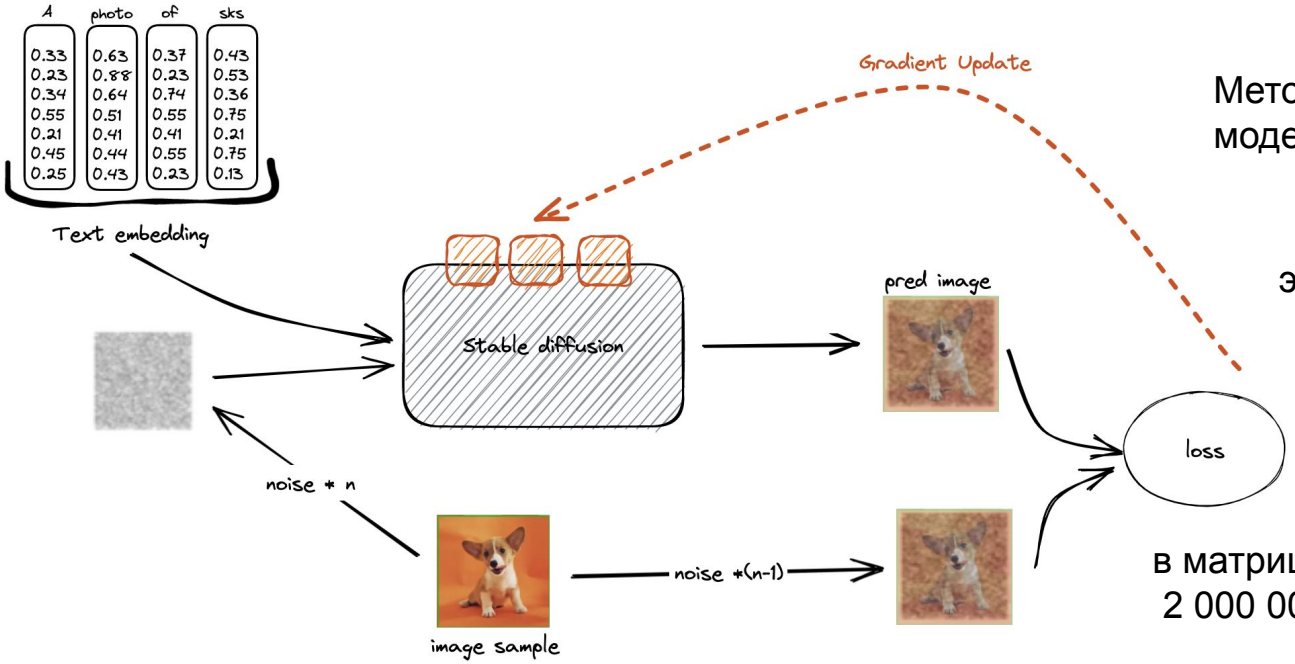

Метод для больших языковых моделей

экономит ресурсы и место

в матрице размером 1000*2000
2 000 000 параметров

$$\mathbf{C} = \mathbf{A} \cdot \mathbf{B} = \begin{pmatrix} 0 & 0 \\ 0 & 0 \\ 0 & 0 \\ 0 & 0 \end{pmatrix} \cdot \begin{pmatrix} 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 \end{pmatrix} = \begin{pmatrix} 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 \end{pmatrix}$$

в матрицах размером 1000*2 и 2000*2
6 000 параметров

HeperNetwork

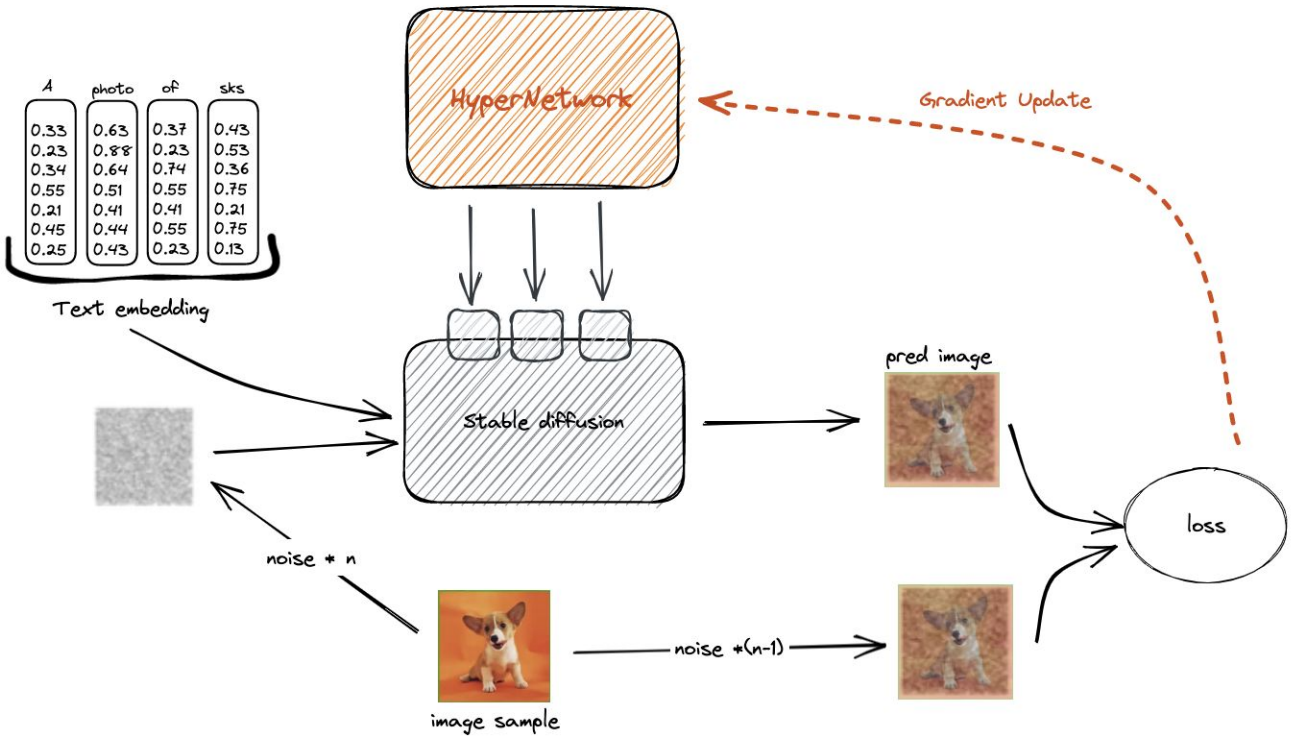

That's all Folks!